

PROGRESSION DE LA FIBROSE PULMONAIRE

PRESENTER PAR **ERRIFAIY JASSIM**
EN CADRÉE PAR **MERZOUQI MARIA**





Dans cette étude, nous exploitons des **images CT thoraciques**, reconnues pour leur haute précision dans la visualisation des structures pulmonaires. L'identification manuelle de la fibrose étant complexe et chronophage, afin de **détecter efficacement la fibrosées** et d'améliorer la rapidité et la fiabilité de l'analyse médicale.



PLAN

- I. INTRODUCTION**
- II. PROBLÉMATIQUE ET OBJECTIF DU TRAVAIL**
- III. C'EST QUOI UN CT (SCANNER)**
- IV. PHYSIOPATHOLOGIE SIMPLIFIÉE DE LA FIBROSE PULMONAIRE**
- V. MÉCANISME D'APPARITION DE LA FIBROSE PULMONAIRE**
- VI. VISUALISATION D'UNE IMAGE DICOM ORIGINALE ET ANALYSE DE SON HISTOGRAMME À PARTIR DU DATASET**
- VII. VISUALISATION D'UNE IMAGE DICOM EGALISÉE ET ANALYSE DE SON HISTOGRAMME À PARTIR DU DATASET**
- VIII. VISUALISATION D'UNE IMAGE DICOM CLAHE ET ANALYSE DE SON HISTOGRAMME À PARTIR DU DATASET**
- IX. MODÈLES ET RÉSULTATS**
- X. APPLICATION ET CONCLUSION**

PROBLEMATIQUE :

Comment développer un algorithme de traitement d'image pour extraire automatiquement la fibrose à partir d'images CT thoraciques ?






C'EST QUOI UN CT (SCANNER) ?




CT (Computed Tomography), ou **tomodensitométrie**, est un examen d'imagerie médicale utilisant les **rayons X** pour produire des images en **coupes détaillées** du corps. En pneumologie, le CT thoracique est l'examen de référence pour détecter des maladies comme la **fibrose pulmonaire**, grâce à sa haute résolution et à l'analyse précise des poumons.

PHYSIOPATHOLOGIE SIMPLIFIÉE DE LA FIBROSE PULMONAIRE



- Cette image illustre les **facteurs impliqués dans le développement des fibroses pulmonaires**, en particulier la **fibrose pulmonaire idiopathique (FPI)**.
- La fibrose pulmonaire résulte d'une atteinte du pneumocyte de type II, cellule clé de la réparation pulmonaire.
- Les facteurs environnementaux comme le tabac, la pollution ou le reflux gastro-œsophagien provoquent des lésions répétées.

MÉCANISME D'APPARITION DE LA FIBROSE PULMONAIRE




La fibrose pulmonaire résulte de l'action combinée de facteurs **intrinsèques** (génétiques, vieillissement) et **extrinsèques** (médicaments, virus, tabac, particules).



Ces facteurs provoquent un **stress du réticulum endoplasmique (RE)** dans les cellules pulmonaires.

Ce stress entraîne l'**activation de voies inflammatoires** (cytokines, chimiokines, ROS...).

En réponse, les **fibroblastes** s'activent, migrent et se multiplient anormalement.




□ l'image originale (Original DICOM)




- **-1000 HU** → air,
- **0 HU** → eau,
- **> +1000 HU** → os.

Histogramme - Image Originale




- **Air** $\approx$ -1000 HU
- **Tissu pulmonaire** $\approx$ -800 à -500 HU
- **Eau** $\approx$ 0 HU
- **Os** $\approx$ +1000 HU et plus

Image Après Égalisation du Contraste




Histogramme - Image Égalisée




Remarque:

- Ce **pic très élevé** correspond à la **majorité des pixels de l'image**, c'est-à-dire les zones :
 - ✓ **d'air dans les poumons, et certaines zones sombres** à faible densité.
 - ✓ Puis une **répartition plus étalée et plus plate** entre **0.3 et 1.0**.

CLAHE (Méthode Avancée)



Histogramme - CLAHE



I. MODÈLE DE MACHING LEARNING

- ✓ PARAMÈTRES
- ✓ LES RÉSULTATS DE ENTRAÎNEMENT
- ✓ PRÉDICTIONS ET LES VALEURS RÉELLES | LE TEST DE MODÈLE

II. MODÈLE DE DEEP LEARNING

- ✓ DATASET + TRANSFORMS (AVEC AUGMENTATION)
- ✓ SPLIT TRAIN/VAL + SAMPLER (ÉQUILIBRAGE RÉEL)
- ✓ MODÈLE CNN, FONCTION DE PERTE ET OPTIMISEUR
- ✓ ENTRAÎNEMENT PAR ÉPOQUES + ÉVALUATION
- ✓ MATRICE DE CONFUSION
- ✓ HISTOGRAMME DES PROBABILITÉS PAR CLASSE



I. MODÈLE DE MACHING LEARNING



PARAMÈTRES:


```
models = {  
    'Random Forest': RandomForestRegressor(**config.MODELS_CONFIG['random_forest']),  
    'XGBoost': xgb.XGBRegressor(**config.MODELS_CONFIG['xgboost'], objective='reg:squarederror'),  
    'LightGBM': lgb.LGBMRegressor(**config.MODELS_CONFIG['lightgbm'], objective='regression', verbose=-1),  
    'Gradient Boosting': GradientBoostingRegressor(  
        n_estimators=100, learning_rate=0.1, max_depth=5, random_state=config.RANDOM_STATE  
    ),  
    'Ridge': Ridge(alpha=1.0, random_state=config.RANDOM_STATE),  
    'Lasso': Lasso(alpha=1.0, random_state=config.RANDOM_STATE)  
}
```

LES RÉSULTATS DE ENTRAÎNEMENT :

	Modèle	RMSE (CV)	Écart-type	RMSE (train)	MAE (train)	R ² (train)
3	Gradient Boosting	46.788573	9.425418	16.886509	12.844793	0.999589
0	Random Forest	55.687962	12.170156	22.655832	11.429479	0.999259
1	XGBoost	64.348644	10.330871	10.884128	8.028260	0.999829
2	LightGBM	64.933352	17.706369	34.573629	21.583088	0.998275
5	Lasso	161.998576	10.784907	159.865728	108.193641	0.963124
4	Ridge	162.083690	10.849088	159.838590	108.003167	0.963137

🏆 Meilleur modèle: Ridge
RMSE (CV): 162.0837

PRÉDICTIONS ET LES VALEURS RÉELLES | LE TEST DE MODÈLE




Sévérité détectée: Sévère
Score de fibrose: 0.8976
Zone affectée: 89.76%



II. MODÈLE DE DEEP LEARNING




DATASET + TRANSFORMS (AVEC AUGMENTATION)



Le **dataset** est structuré par **patient** et combine des **images CT** et des **données cliniques**. Des **transformations avec augmentation** (rotation, flip, normalisation, redimensionnement) sont appliquées aux images pour augmenter la diversité des données et améliorer la robustesse du modèle. Cette stratégie réduit le surapprentissage et améliore la généralisation.

L'image montre comment on combine **imagerie CT + données cliniques**, puis comment l'**augmentation de données** améliore la performance et la fiabilité du modèle de classification de la fibrose pulmonaire.

SPLIT TRAIN/VAL + SAMPLER (ÉQUILIBRAGE RÉEL)




Les données sont divisées en **train/validation** avec un **Stratified K-Fold** au **niveau patient**, assurant une répartition équilibrée des classes et évitant toute fuite de données. Un **WeightedRandomSampler** est appliqué à l'entraînement pour compenser le déséquilibre des classes en favorisant la classe minoritaire, ce qui stabilise l'apprentissage et améliore la détection des patients atteints, tout en gardant une validation représentative.

MODÈLE CNN, FONCTION DE PERTE ET OPTIMISEUR

Modèle CNN (ResNet18) + Loss + Optimiseur

Split patient + échantillons équilibrés



Un **ResNet18 pré-entraîné** est utilisé comme modèle CNN, avec une **sortie binaire** adaptée à la détection de la fibrose.

L'entraînement s'appuie sur la **BCEWithLogitsLoss** pour une classification stable et sur l'optimiseur **Adam** avec un faible taux d'apprentissage et une régularisation afin de limiter le surapprentissage.

ENTRAÎNEMENT PAR ÉPOQUES + ÉVALUATION

Résultats Cross-Validation : K-Fold sur Dataset Médical

Faible validation → AUC élevés mais variables

83 patients
K-Fold Stratifié



~16 patients par fold



- ✓ train_loss baisse
- ✓ AUC élevés globalement
- ✓ Fold 1 : 0.52 → 1.00
- ✓ Fold 2 : 0.42 → 0.94

Fold 1

AUC 1.0

AUC 0.42

Fold 2

AUC 0.94

AUC 0.92

Fold 3

AUC 0.97

AUC 0.97

Fold 4

AUC 0.80

AUC 0.80

Fold 5

AUC 1.0

AUC 1.0

Seulement ~17 patients en validation →

→ Amplification (AUC possibles = 1 jusqu'à 4%)

✓ Variabilité des résultats (ce qui est normal)

✓ Bonnes performances

✓ Variabilité inter-folds

✓ Le modèle est performant
mais variable selon les folds
(normal avec 83 patients)




Les résultats montrent que le modèle apprend correctement (**train loss en baisse**) et obtient de **bonnes performances en validation** avec des **AUC élevées** sur la plupart des folds.

Les valeurs **AUC = 1.0** apparaissent sur certains folds en raison du **faible nombre de patients en validation**, ce qui peut amplifier les performances.

Globalement, le modèle est performant mais présente une **variabilité entre folds**, ce qui est normal avec un dataset de taille limitée.


- ✓ **AUC global:** 0.94
- ✓ **AUC folds mean:** 0.93
- ✓ **std:** 0.075

ROC (RECEIVER OPERATING CHARACTERISTIC)



La courbe ROC montre une **excellente capacité de discrimination** du modèle à partir des images CT. Avec une **AUC = 0.946**, le modèle distingue efficacement les patients fibrosés des non fibrosés, bien au-dessus du hasard, ce qui confirme sa **bonne performance diagnostique**.

MATRICE DE CONFUSION




34 vrais négatifs (TN) : patients
Slow correctement prédits

40 vrais positifs (TP) : patients
Rapid correctement détectés

6 faux positifs (FP) : patients Slow
prédits à tort comme Rapid

3 faux négatifs (FN) : patients
Rapid manqués par le modèle

HISTOGRAMME DES PROBABILITÉS PAR CLASSE



les patients **Slow** ont majoritairement des probabilités faibles, tandis que les patients **Rapid** ont des probabilités élevées.

Le **chevauchement limité** correspond aux cas ambigus et explique les rares erreurs.

Globalement, la distribution confirme la **bonne capacité de discrimination** du modèle.




TEST



SAUVEGARDE, RECHARGEMENT ET ÉVALUATION SÉCURISÉE DU MODÈLE

Sauvegarde, Rechargement et Évaluation Sécurisée du Modèle



PRÉPARATION DES DONNÉES POUR TESTER LE MODÈLE


```
** Requirement already satisfied: pydicom in /usr/local/lib/python3.12/dist-packages (3.0.1)
AUC: 0.9912891986062717
Confusion Matrix:
[[37  5]
 [ 0 41]]

Classification Report:
              precision    recall  f1-score   support


   Slow(0)         1.00      0.88      0.94         42
   Rapid(1)         0.89      1.00      0.94         41

 accuracy              0.94         83
 macro avg           0.95      0.94      0.94         83
 weighted avg        0.95      0.94      0.94         83
```

ROC (RECEIVER OPERATING CHARACTERISTIC - AREA UNDER THE CURVE)



VISUALISATION DE CONFUSION MATRIX




37 vrais négatifs (TN) : patients Slow correctement prédits

41 vrais positifs (TP) : patients Rapid correctement détectés

5 faux positifs (FP) : patients Slow prédits à tort comme Rapid

0 faux négatifs (FN) : patients Rapid manqués par le modèle


L'HISTOGRAMME DES PROBABILITES



Les patients Slow (0) ont majoritairement des probabilités faibles (proches de 0).

Les patients Rapid (1) ont des probabilités élevées (proches de 1).

LA COURBE PRECISION-RECALL



La courbe reste très haute, avec une Average Precision (AP) = 0,99, ce qui indique des prédictions très fiables.

Le modèle détecte presque tous les cas Rapid (rappel élevé) tout en faisant très peu de faux positifs (précision élevée).

le modèle est très performant, en particulier pour identifier correctement les patients à progression rapide.

CREATION D'INTERFACE WEB POUR NOTRE MODELE





SAIN & MALADE

TESTER LE MODELE SUR UN PATIENT SAIN

OSIC – Prédiction Fibrose (Fusion CNN + Clinique)

Choisis un Patient ID (dossier DICOM dans `train/`) puis clique Prédire.

Patient ID (train/)

ID00007637202177411956430

Seuil de décision

0.05  0.95

0,5 

Prédire

Patient: ID00007637202177411956430

Proba(Rapid=maladie): 0.246

Prédiction: Slow (non) (seuil=0.5)

Vrai label (dataset): Rapid (maladie)

Clinique (raw): age=79, sex=1, smoke=1, percent=58.3, fvc0=2315, slope=-3.167

TESTER LE MODELE SUR UN PATIENT MALADE

OSIC – Prédiction Fibrose (Fusion CNN + Clinique)

Choisis un Patient ID (dossier DICOM dans [train/](#)) puis clique Prédire.

Patient ID (train/)	Seuil de décision	0,5	↺
ID00010637202177584971671	0.05		

Prédire

Patient: ID00010637202177584971671

Proba(Rapid=maladie): 0.995

Prédiction: Rapid (maladie) (seuil=0.5)

Vrai label (dataset): Slow (non)

Clinique (raw): age=60, sex=1, smoke=1, percent=94.7, fvc0=3523, slope=-17.043

CONCLUSION

Ce travail a abouti à la mise en place d'un **système de prédiction fiable et robuste** pour l'évolution de la fibrose pulmonaire, reposant sur une **fusion intelligente des données d'imagerie DICOM et des informations cliniques**.

Les performances élevées obtenues lors des phases de validation et de test démontrent la **pertinence de l'approche méthodologique**, ainsi que la capacité du modèle à généraliser sur des données réelles.

Ce projet met en évidence l'intérêt des techniques de **deep learning multimodal** en santé et ouvre des perspectives concrètes pour le **développement d'outils d'aide à la décision médicale**, tout en laissant place à des améliorations futures telles que l'intégration de données longitudinales plus riches et la validation sur des cohortes élargies.



MERCI

Avez-vous des questions ?

Contact.errifaiy@gmailcom